

0) Задание состоит в том, чтобы расширить имеющуюся программу в последнем задании с использованием MPI+CUDA/MPI+OpenACC/CDVMH.

- 1) Срок **начала** сдачи программы – не позднее **9 декабря** (желательно раньше), срок **окончания** сдачи – **16 декабря**, далее задачи будут приниматься только в модели DVMH.
- 2) Программа должна быть на MPI + CUDA, MPI+OpenACC или в модели CDVMH либо с полным распараллеливанием, либо MPI+DVMH. Использование библиотек cuBLAS/cuSPARSE запрещается.
- 3) Программа должна собираться через makefile, в котором обязательно должны быть две переменные **ARCH=sm_<N>** (где **N = 35 / 60**), обозначающая архитектуру GPU, и **HOST_COMP=mpicc**, обозначающая хост компилятор. Эти переменные должны использоваться как минимум для **nvcc**. Запрещается использовать возможности CUDA > cc 3.5.
- 4) Отчет о выполнении должен содержать в себе все предыдущие этапы задания, то есть распараллеливание на MPI, OpenMP, а также MPI + GPU.
- 5) В отчете должны содержаться все времена запусков задачи на том количестве процессоров, которое требуется. Также должны быть получены графики ускорения и эффективности, по отношению к **последовательной** (исходной!) программе без MPI / OpenMP.
Опционально можно посчитать ускорения различных параллельных версий между собой.
- 6) Программа на MPI + GPU должна работать **НЕ медленнее**, чем MPI, OpenMP. Если количество данных не хватает для получения «хороших» цифр на GPU, следует увеличить исходные размеры массивов.
- 7) Отчет должен содержать пояснение по тем результатам, которые были получены – каков характер ускорений, эффективности, каковы причины такого поведения, если полученные цифры не совпадают с прогнозируемыми.
- 8) В отчете должно быть указано, каким образом производилась оценка корректности выполнения параллельных версий, в особенности MPI + GPU.
- 9) В отчете должны содержаться не только общее время работы программы, а также времена всех параллельных циклов, времена инициализации и завершения работы программы, времена копирования данных с GPU на хост и обратно, времена коммуникационных обменов (если они асинхронные, то демонстрация того, что они не занимают времени) как в исходной, последовательной программе, так и в параллельной. Таким образом, таблица, содержащая времена запусков, должна содержать помимо общего времени, времена всех затрат на коммуникации и обмены между GPU, а также времена параллельных циклов.
- 10) **Запрещается** использование разделяемой памяти для реализации редукции. Использование разделяемой памяти где-либо требует обоснования в отчете.
- 11) **Для сдачи необходимо загрузить код в любой git-репозиторий** и включить ссылку в отчет (или прислать ссылку на этот репозиторий в личном сообщении). В данном репозитории желательно иметь историю коммитов и изменений в процессе распараллеливания задачи, а также исходный код программы (в разных ветках последовательный и параллельный) и готовый отчет.

Невыполнение **хотя бы одного** из этих пунктов приведет к дополнительной итерации сдачи задания для реализации не выполненных пунктов.

PS: Производительность IBM Power 8 DP – 0.3 Tflops, Tesla P100 – 4.7 Tflops

Скорость памяти IBM Power 8 – for 1 TB RAM – 230 GB/s, Tesla P100 – 700 GB/s

Из этих соотношений ясно, что для GPU может быть получена достаточно хорошая программа при условии оптимальности кода.